

Résumé du Rapport : Modèle d'Actions Étendues pour l'Automatisation Web

Abdeljalil Nabaoui
Université de Luxembourg
Email: abdeljalil.nabaoui.001@student.uni.lu

Ce rapport a été produit sous la supervision de:
Salima Lamsiyah
Université de Luxembourg
Email: salima.lamsiyah@uni.lu

Résumé

Ce projet vise à développer un système avancé pour l'automatisation des tâches sur YouTube, en utilisant une combinaison de modèles de langage naturel et de bibliothèques d'automatisation telles que Selenium. L'objectif principal était de créer un pipeline capable de comprendre une tâche donnée en langage naturel, de la décomposer en sous-tâches précises et de générer du code Python pour exécuter ces sous-tâches dans un navigateur Web. Le système se distingue par sa capacité à gérer les erreurs en temps réel et à améliorer l'exécution à travers des interactions utilisateur basées sur des retours visuels.

L'automatisation des tâches spécifiques sur YouTube inclut des actions comme la recherche de vidéos, la gestion des cookies, et la lecture de contenu. Par exemple, une tâche complexe comme rechercher une compilation drôle sur YouTube et jouer la première vidéo est décomposée automatiquement en étapes élémentaires, telles que ouvrir YouTube ou entrer la requête de recherche. Chaque étape est ensuite traduite en code exécuté via Selenium, garantissant une interaction continue avec le site. Le système prend en compte des scénarios dynamiques, tels que l'apparition d'annonces ou de fenêtres contextuelles, grâce à l'intégration de modèles de vision comme CLIP.

Contributions principales

- **Génération d'instructions précises** : Un modèle de langage (Mistral LLM) est utilisé pour transformer les tâches globales en étapes simples et cohérentes.
- **Génération de code automatisée** : À partir des instructions générées, un modèle tel que ChatGPT produit des fragments de code Python optimisés pour Selenium.
- **Interaction interactive avec l'utilisateur** : En cas d'échec, l'utilisateur fournit des retours qui sont intégrés dans des boucles de correction, permettant une amélioration progressive.
- **Analyse visuelle** : Des captures d'écran sont analysées via le modèle CLIP pour valider l'état du navigateur et

guider les prochaines étapes.

Méthodologie

Le pipeline est conçu pour intégrer plusieurs outils avancés. Une tâche en langage naturel est d'abord interprétée par un modèle de langage qui génère une étape claire. Cette étape est transformée en code Python-Selenium par un autre modèle. Chaque exécution est surveillée en temps réel via des captures d'écran, et des ajustements sont effectués si nécessaire. Ce processus garantit que même les changements dynamiques sur YouTube, comme les modifications de structure ou l'apparition de dialogues de cookies, sont gérés efficacement.

Le système repose sur des boucles itératives : après chaque étape, une validation est effectuée à travers des outils visuels (CLIP) et des retours utilisateurs. En cas d'échec, des corrections automatiques sont tentées en fonction des erreurs identifiées.

Résultats expérimentaux

Les expériences montrent que le système est capable de réaliser des tâches complexes avec un haut degré d'efficacité. Par exemple, pour la tâche rechercher une compilation drôle sur YouTube et jouer la première vidéo, le système a réussi à exécuter toutes les étapes en une moyenne de trois instructions et un temps total d'environ 35 secondes. Toutefois, certaines limitations ont été observées, notamment des erreurs liées aux annonces intégrées ou à des sélecteurs dynamiques imprévisibles. Les capacités interactives du système, notamment les corrections basées sur des retours, ont permis de surmonter ces défis dans la plupart des cas.

Perspectives d'avenir

Bien que le projet soit actuellement limité aux interactions sur YouTube, les prochaines étapes incluent l'extension à d'autres plateformes, comme les réseaux sociaux ou les sites de commerce électronique. L'intégration de modèles plus performants pour la vision par ordinateur et la gestion

d'autres frameworks (par exemple, Playwright) offrirait une flexibilité accrue. À long terme, ce projet vise à généraliser l'automatisation des tâches web en combinant des capacités de compréhension du langage et d'analyse dynamique des interfaces.